

Привет !! 2021-10-15

- 1) линейный регресс + регрессия
- 2) регрессия t-статистики
- 3) про нормальное распр-ие и прецеденты

Постановка 1.

линейная модель + Метод наименьших квадратов

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \quad X = \begin{bmatrix} & \\ & \\ & \end{bmatrix} \quad \begin{matrix} \uparrow \\ n \end{matrix}$$

\longleftrightarrow
k

$$\hat{y} = X \cdot \hat{\beta}$$

$$\hat{\beta} [k \times 1]$$

традиционно

$$X = \begin{bmatrix} 1 & z_1 & w_1 \\ 1 & \vdots & \vdots \\ 1 & \vdots & \vdots \\ \vdots & \vdots & \vdots \\ 1 & z_n & w_n \end{bmatrix} [n \times k]$$

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 \cdot z_i + \hat{\beta}_3 \cdot w_i$$

как оценить $\hat{\beta}$?

$$\hat{E}(y_i | z_i, w_i)$$

→ МНК

$$\min_{\hat{\beta}} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\hat{\beta}_{OLS}$$

OLS = ordinary least squares = МНК

$$\hat{Med}(y_i | z_i, w_i)$$

линейная
регрессия

$$\min_{\hat{\beta}} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\hat{\beta}_n$$

$$\hat{Quant}_p(y_i | z_i, w_i)$$

квантильная
регрессия

$$\min_{\hat{\beta}} \sum_{i=1}^n \left(p \cdot |y_i - \hat{y}_i| \cdot I(y_i \geq \hat{y}_i) + (1-p) \cdot |y_i - \hat{y}_i| \cdot I(y_i < \hat{y}_i) \right)$$

Факт из теории вероятей

YFB

y — одна с.в.-ка (не вектор)

$$\min_{\alpha} E[(y - \alpha)^2] \Rightarrow \alpha^* = E(y)$$

[распр y несп]

$$\min_{\alpha} E(|y - \alpha|) \Rightarrow \alpha^* = \text{Med}(y)$$

[распр y несп]

$$\min_{\alpha} E \left[p|y - \alpha| \cdot I(y \geq \alpha) + (1-p)|y - \alpha| \cdot I(y < \alpha) \right]$$

$0 < p < 1$

$$\alpha^* = \text{quantile}_p(y)$$

если:

$p = 0.9999 \quad \alpha^* = \max(y)$
 $p = 0.0001 \quad \alpha^* = \min(y)$

Стор

$$\hat{\beta} = \begin{pmatrix} 2 \\ 1 \\ 3 \end{pmatrix}$$

$$\min_{\hat{\beta}} Q(\hat{\beta})$$

$$\text{Med}(y_i | w_i, z_i) = 2 + 1 \cdot w_i + 3z_i$$

$\hat{\beta}_1$ $\hat{\beta}_2$ $\hat{\beta}_3$

точность оценивания $\hat{\beta}$?

хотим:

CI 95% для β

самый простой способ — наименьший суммарный (карманы)

1	y_1	1	w_1	z_1
2	\vdots			
	y		X	
	\vdots			
n	y_n	1	w_n	z_n



$$\hat{\beta}_{\text{Med}}$$

$$\min_{\hat{\beta}} \sum |y_i - \hat{y}_i|$$

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 \cdot w_i + \hat{\beta}_3 z_i$$

каждая строка — наблюдение:
у исходных и наблюд.-их переменных
и (с возможностью
появ. выбора) служеб-
но, равновер-но.

...




CI β_w ? 95%

CI = confidence interval

$$\beta_w \in [q_L(\hat{\beta}_w^*); q_K(\hat{\beta}_w^*)]$$

Теорема "Бут стрен (гоме наивности) работает"

- если 1) модель - линейная регрессия
2) $\text{Med}(y_i | X) = x_i^T \cdot \beta$
3) $(y_i | X) \sim \text{непрер-ная}$



то : при $n \rightarrow \infty$


$$\text{row}_i X = x_i^T$$

$$P(\beta_w \in [q_L(\hat{\beta}_w^*); q_K(\hat{\beta}_w^*)]) \rightarrow 1 - \alpha$$

Хотим сж-ые подстроки!

МНК при идеальных условиях.

Тогда рассказ про N:



def Говорят, что $X \sim N(\mu; \sigma^2)$ на сур-ие, если

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

откуда эта формулировка??
и? е?

Правильный рассказ про N

Var $\rightarrow 1$

35°, 36°, 37°, 48°

$$\hat{\mu} = \frac{y_1 + \dots + y_n}{n}$$

"усреднили"

действие надл.
кажд. зреть
с меньшим весом

$$\hat{\mu} = ?35^\circ + ?36^\circ + ?37^\circ + ?48^\circ$$

Гauss

- 1) истинное μ
- 2) y_i - к-с. величины сам по распр от μ
- 3) "усреднили правильно"

3) имеющиеся данные наиболее вероятна (плотность) при $\mu = \bar{y}$

пол-ть $\rightarrow f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

↓
гип. ур

Воп-т 2. Аксиоматика Хермита-Матвева.

$$X = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

в орт. системе коорд-т
скорости случайн. побл-об
распредел.

$$(R \cdot x) \quad R^T R = I$$

Rot Inv. Закон расп-ия x не изм-ся, если
изм. систему коорд-т повернув.

закон π

$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

$$\tilde{x} = \begin{pmatrix} \tilde{x}_1 \\ \tilde{x}_2 \\ \tilde{x}_3 \end{pmatrix}$$


x и \tilde{x} —
— скорости
в разных
(орт-х) сист. коорд.

$$P(x_1 \leq t_1, x_2 \leq t_2, x_3 \leq t_3) = \\ = P(\tilde{x}_1 \leq t_1, \tilde{x}_2 \leq t_2, \tilde{x}_3 \leq t_3)$$

Proj Inv

независимость орт-х проекций
 \mathbb{R}^n

закон e
проект



если $V_1 \perp V_2$

и \hat{x}_1 и \hat{x}_2 —

это проекции x
на V_1 и V_2 , то
 \hat{x}_1 и \hat{x}_2 незав.

$[X-M]$

Определение: Мы говорим, что $x \sim N(0; \sigma^2 \cdot I)$, если
 x удовл-т $[Rot Inv]$ и $[Proj Inv]$ выполнены.

Теорема Орт-н $X-M$ и классическое (с плотностью)
эквивалентны.

показано
Галкин \rightarrow [при дан. предп-ке, f -функция плотности существует].
 \rightarrow [для $n=2$]

$$f(x_1, x_2) \stackrel{[Proj]}{=} f_1(x_1) \cdot f_2(x_2) \stackrel{[Rot]}{=} \underline{f(x_1)} \cdot \underline{f(x_2)} \quad \forall x_1, x_2$$

$$f(x_1) = \int_{\mathbb{R}} f(x_1, x_2) dx_2$$

[Rad] $f(x_1, x_2)$ и. габусець раўнаю а $x_1^2 + x_2^2$
 [Rad] $f(x_1)$ и. габусець раўнаю а x_1^2

$$f(x_1, x_2) = l(x_1^2 + x_2^2)$$

$$f(x_1) = z(x_1^2)$$

$$l(x_1^2 + x_2^2) = z(x_1^2) \cdot z(x_2^2) \quad \forall x_1, x_2$$

$$\begin{cases} l(a+b) = z(a) \cdot z(b) \\ l'(a+b) = z'(a) \cdot z(b) \end{cases} \quad \begin{aligned} a &= x_1^2 \\ b &= x_2^2 \\ \forall a, b \\ a &= 0 \end{aligned}$$

$$\begin{cases} l(b) = z(0) \cdot z(b) \\ l'(b) = z'(0) \cdot z(b) \end{cases}$$

$$l'(b) = l(b) \cdot \frac{z'(0)}{z(0)} \quad \forall b$$

const


$$l(b) = c \cdot \exp(k \cdot b)$$

$$f(x_1, x_2) = l(x_1^2 + x_2^2) = c \cdot \exp(k \cdot (x_1^2 + x_2^2))$$

$$\int_{\mathbb{R}^2} f(x_1, x_2) dx_1 dx_2 = 1 \Rightarrow k < 0$$

$$k = -\frac{1}{2\sigma^2}$$

$$f(x_1, x_2) = c \cdot \exp\left(-\frac{1}{2\sigma^2}(x_1^2 + x_2^2)\right)$$



$$\int_0^c \pi \cdot z(t) dt = 1$$

$$t = c \cdot \exp\left(-\frac{1}{2\sigma^2}(x_1^2 + x_2^2)\right)$$

$$x_1^2 + x_2^2 = r^2(-t)$$

$$\ln t = \ln c - \frac{1}{2\sigma^2}(x_1^2 + x_2^2)$$

$$x_1^2 + x_2^2 = (\ln c - \ln t) \cdot 2\sigma^2$$

$$\int_0^c \pi (\ln c - \ln t) \cdot 2\sigma^2 dt = 1$$

$$\rightarrow c = \frac{1}{2\pi\sigma^2}$$

$$f(x_1, x_2) = \frac{1}{2\pi\sigma^2} \cdot \exp\left(-\frac{1}{2\sigma^2}(x_1^2 + x_2^2)\right)$$

4

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}; \begin{pmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{pmatrix}\right)$$